

- Probabilidad incondicional

+ Conceptos básicos

* $0 \leq P(a) \leq 1$; $P(a)=1$: true; $P(a)=0$: false

* $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$; si a y b son disjuntas: $P(a \vee b) = P(a) + P(b)$

* $P(\neg a) = 1 - P(a)$

* $\sum_{i=1}^n P(D=d_i) = 1$; La suma de las probabilidades de cada variable que forma D , es 1

+ Eventos atómicos

Proposiciones elementales que dan valor a todas las variables del conjunto.

Toda proposición es equivalente a la disyunción de un conjunto de eventos atómicos

Ej: patata = (patata \wedge queso) \vee (patata \wedge \neg queso);

De forma general: $P(a) = \sum_{e_i \in E(a)} P(e_i)$ # $P(a)$ es el sumatorio de las probabilidades de los eventos atómicos de a

Estos eventos se organizan mediante una tabla de distribución conjunta, en la que se colocan como filas la consecuencia y como columnas las variables que la preceden:

Ej: Estudiamos ~~el~~ los casos posibles p, sabiendo que puede ser consecuencia de q, r o ambos

	q	$\neg q$	r	$\neg r$
r				
$\neg r$				
p				
$\neg p$				

Estas podrían ser las probabilidades posibles para cada caso: 2 filas \times 4 columnas (ya que "q y r" se estudian a lo largo)

Ejemplo de forma general: $P(q \vee p) = P(p \vee q)$

$$P(p \vee q) = P(p, q, r) + P(p, q, \neg r) + P(p, \neg q, r) + P(p, \neg q, \neg r) + P(\neg p, q, r) + P(\neg p, q, \neg r)$$

Suma de todos los eventos que satisfacen $P(p \vee q)$

- Probabilidad condicional

+ Conceptos básicos

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

Probabilidad de que se da a saliendo que se da b .

$P(a \wedge b)$ se puede escribir como $P(a,b)$

Hablemos siempre de creencias; no de evidencias conocidas

+ Normalización

A la hora de calcular una probabilidad condicional, podemos calcularla con la fórmula anterior o calcular la probabilidad de que se cumpla $\neg b$; y, normalizarla (hacer que ambas sumen 1) mediante sumar

Ej: $P(p|q)$

$$1) P(p|q) = \frac{P(p \wedge q)}{P(q)} ; 2) P(p|q) = \alpha [P(p,q,r), P(p,q,\neg r)]$$

2) Habrá que estudiar tanto el caso de p , como el de $\neg p$; y sumar los casos positivos y negativos para separando para después normalizarlo

+ Independencia probabilística

Das variables son independientes si conocer el valor de ella no afecta el grado de creencia de la otra.

Ej: $P(x|y) = P(x) ; P(y|x) = P(y) ; P(x,y) = P(x) \cdot P(y)$

Ej: $P(q|p,r) = P(q|p)$ # q es independiente de r (independencia condicional)

Ej: Sabiendo que q y r dependen de p ; podemos decir que:

$$P(p,q,r) = P(p) \cdot P(q|p) \cdot P(r|p)$$

De forma general: $P(\text{causa}, E_1, \dots, E_n) = P(\text{causa}) \prod P(E_i | \text{causa})$

La probabilidad de una causa y una serie de efectos (que viene dada en P) es el producto de las probabilidades de la causa y la probabilidad de cada evento dada la causa, es decir, producto de las probabilidades con sus precondiciones, si no tiene, serán las probabilidades de dicha variable

- Redes bayesianas

Una red bayesiana es un grafo acíclico dirigido

+ Características básicas

1º Cada nodo representa una variable aleatoria

2º Los arcos entre X e Y definen los padres $A \rightarrow B$ (B depende de A)

3º Cada nodo contiene una distribución probabilística con sus padres $P(X_i | \text{padres}(X_i))$

Con las redes bayesianas podemos ver claramente las independencias entre ciertas variables del "mundo"

La mayoría de las redes bayesianas frente a los DCC es de: ~~n^{n+1}~~

$n \cdot 2^n$ frente a 2^n (siendo n las variables y K la influencia ^{max} media)

+ Construcción de redes bayesianas

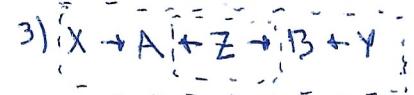
Para facilitar la construcción de la red, comenzar por las percepciones que no dependen de otras y desarrollar a partir de ahí

+ D-separa

Una vez dibujada la red bayesiana se puede declarar la independencia mediante d-separación. Para que dos variables X e Y estén d-separadas es por lo tanto sean condicionalmente independientes:

1- Pasar por un elemento que es parte del conjunto dado ($Z \in \mathbb{Z}$) con arcos en el mismo sentido o divergentes.

Ej.: Dado $\{Z\}$ el camino entre X e Y es condicionalmente independiente (d-separa)



2- Pasar por un elemento que no es parte del conjunto dado ($Z \notin \mathbb{Z}$) con arcos convergentes y ningún descendiente de Z esté en \mathbb{Z}

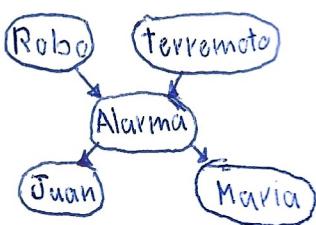
Ej.: Dado $\{C\}$ el camino entre X e Y es condicionalmente independiente (d-separa)



+ Información probabilística en una red bayesiana

Calcular la probabilidad clacular una consulta (efecto) y evidencias.

Para entender mejor como desarrollarlo usaremos el ejemplo de los diapos.



$$P(\text{Robo} \wedge \text{Juan}, \text{maría}) = \langle P(r|j,m); P(t|r,j,m) \rangle = 1$$

$$1) = \alpha \sum_{\tau} \sum_A P(r, t, A, j, m); \sum_{\tau} \sum_A P(\tau, t, A, j, m) = 2$$

$$2) = \alpha \left(\sum_{\tau} \sum_A P(r) P(t) P(A|r, t) P(j|A) P(m|A) \right)$$

$$\sum_{\tau} \sum_A P(\tau) P(t) P(A|\tau, t) P(j|A) P(m|A) \right)$$

- 1) Estamos buscando la probabilidad de un robo si juan y maría han llamado, para ello, estudiaremos los casos separados para r y τr , después lo normalizaremos.
- 2) Vamos a estudiar $P(r|j,m)$, sabiendo que j y m son evidencia y para ello tenemos que hacer una ~~suma del producto~~ de $P(r), P(A|r,t), P(j|A)$ y $P(m|A)$; comparando tanto para A , como t el caso positivo y negativo. Luego haremos lo mismo con el caso de $P(\tau r|j,m)$.

+ Algoritmo de eliminación de variables

Partimos del ejercicio anterior como ejemplo. Por la probabilidad a estudiar conocemos las probabilidades de las evidencias; $P(r|j,m) \Rightarrow P(j|A) \wedge P(m|A)$; $\# P(m|A) = f_m(A)$ aquí se pone la variable que no conocemos y suíme punto de $P(j|A)$

Una vez tenemos clara la probabilidad de las evidencias, pasamos a los antecedentes, en este caso $P(A|r,t)$ o $f_A(A,R,T)$ $\#$ No conocemos ninguna variable. En este caso nos lo da la red bayesiana.

Pasaremos a los siguientes antecedentes hasta acabar.

* Eliminación de una variable

Si queremos eliminar una variable de un modelo:

1º Buscar las probabilidades en las que intervienen la variable a eliminar.

Ej: Eliminaremos A del ejemplo.

Las funciones en las que aparecen son $\Rightarrow P(m|A), P(j|A)$ y $P(a|r,t)$ o $f_m(A), f_j(A)$ y $f_a(R,T)$

2º Generamos la tabla sin la variable, para ello, multiplicamos los valores de la variable a eliminar en cada caso, teniendo en cuenta que, los valores que tendrían más cambios serán los de la función de referencia; calculamos los casos positivos y negativos y sus sumatorias.

3º Repetimos el paso 2º hasta quedar con una función que solo tenga como variable desconocida la de consulta y la multiplicamos por los totales de la función de la variable de consulta. Al normalizarla, nos dará la probabilidad que buscábamos al inicio.

+ Observaciones algoritmo de eliminación

Comenzamos con 1 factor por variable y vamos reduciendo:

- 1º Por cada variable que no sea de evidencia o consultar sustituimos los factores por el resultado de eliminar una variable (Partir de las evidencias hasta la consultar).

* Eliminar variable: buscar todos los factores donde aparece, multiplicarlos y sumar las casas positivas y negativas (obteniendo el factor sin variable)

Si la variable es la de consultar solo multiplicamos, ya que queremos el producto positivo y negativo

- 2º cuando llegamos al factor único que solo depende de la variable de consultar, normalizamos el factor y obtenemos el resultado de la inferencia probabilística.

* Operaciones

Multiplicar tablas: partiendo de $f_1(x, y)$ y $f_2(y, z)$, se define el producto $f_{12}(x, y, z)$, cuya entrada es la multiplicación de ambas

Agupar tablas; si $f_{xy}(y, z)$ es un factor (multiplicar x y), su agrupamiento sería eliminar la y, es decir, dejar el factor como $f_x(z)$, resultante de hacer la suma de las columnas para "y" ~~y~~ "z"

Toda variable que no sea antecesora en la red se elimina

+ Inferencias exactas en redes bayesianas

La inferencia exacta es inviable al menos que se haga mediante muestra

* Muestreo o Sampling

consiste en generar eventos en base a una distribución de probabilidad.

Ej muestreo simple: $P(A) = \langle \alpha, 1-\alpha \rangle$, generamos una muestra de números aleatorios entre $[0, 1]$, si sale un valor $<\alpha$ es positiva, sino es $\neg\alpha$

De este forma podemos hacernos una idea del modelo aproximado

* Muestreo a priori

Simplemente con cada variable de independiente a antecesores vamos generando muestras de forma aleatoria y llenando el modelo. Importante, si una probabilidad padre $P(A) = \alpha$, vale negativa (>1), las probabilidades de los dependientes se hacen een $>\alpha$, por ejemplo, $P(B|\neg\alpha, c)$

* Muestreo con rechazo

Con el modelo anterior, generan varios resultados y devolver la probabilidad de un evento dando los resultados.

Ej: Si generamos 100 muestras y de estos 15 son α y de esos 15 solo 2 son b , la $P(b|\alpha) = \langle 2, 13 \rangle$, normalizamos después

+ Ponderación por verosimilitud

consiste en aplicar un peso en base a la probabilidad del evento del que depende, si este es una variable de evidencia.

* Para realizar el algoritmo, hacemos el muestreo normal, pero cuando llegamos a una variable de evidencia calculamos $W \times P$ (el ponderarán), con esto obtenemos un resultado, además del peso de la creencia de este. Las evidencias tendrán el signo de la probabilidad que se busca.

+ tipos de problemas (verano julio 2023)

+ calcular la probabilidad dada una premisa

$$P(a, \neg b, c, e, f)$$

1º Miramos en la red bayesiana si hay alguna variable con dependencia que no aparezca en la red bayesiana; en este caso serán d, que es padre tanto de e, como de f, por lo que hay que calcular la probabilidad sumando tanto el caso positivo, como el negativo.

$$P(a, \neg b, c, e, f) = P(a, \neg b, c, d, e, f) + P(a, \neg b, c, \neg d, e, f)$$

2º Desarrollamos las probabilidades, empezando por el producto de las variables sin padres y multiplicándolas por el producto de las probabilidades de las variables dependientes

$$1) P(a, \neg b, c, d, e, f) = P(a) \cdot P(\neg b) \cdot P(c|a, \neg b) \cdot P(d|a, \neg b) \cdot P(e|d) \cdot P(f|d)$$

+ calcular la probabilidad por eliminación de variables

$$P(B|\neg a, e)$$

Conocemos las evidencias $\neg a$ y e , por lo tanto, sacaremos $P(\neg a)$ y $P(e|d)$.
Como a y e tienen padres, no podemos sacarlos directamente.

1º Organizamos los tablas iniciales con los valores sin dependencia e inciales (evidencia)

F_2 no habrá que ponerla porque es siempre $\neg a$ y e tiene padre; F_3 sumó $\neg a$

		# tomamos los valores			
		C	$f_C(B)$	D	$f_D(D B)$
B	$f_B(B)$	b	0.1	b, d	0.8
b	0.9	b, c	0.7	b, d	0.2
$\neg b$		b, $\neg c$	0.3	$\neg b$, d	0.7
		$\neg b$, c	0.2	$\neg b$, $\neg d$	0.3
		$\neg b$, $\neg c$	0.8		

		# tomamos los valores			
		E	$f_E(E)$	F	$f_F(F D,E)$
B	$f_B(B)$	d	0.1	d	0.4
b	0.9	b, c	0.7	b, d	0.9
$\neg b$		b, $\neg c$	0.3	$\neg b$, d	0.6
		$\neg b$, c	0.2	$\neg b$, $\neg d$	0.1
		$\neg b$, $\neg c$	0.8		

2º Eliminamos Variables

i) Eliminamos D

$$\text{# } f_{B,F}(B, F) = f_E(E) \times f_D(D|B) \times f_F(F|D, E)$$

B	F	d	$\neg d$	$f_{B,F}(B, F)$
b	g	0.1 \times 0.8 \times 0.4	0.9 \times 0.2 \times 0.9	
b	$\neg g$	0.1 \times 0.8 \times 0.6	0.9 \times 0.2 \times 0.1	
$\neg b$	g	0.9 \times 0.7 \times 0.4	0.9 \times 0.3 \times 0.9	
$\neg b$	$\neg g$	0.9 \times 0.7 \times 0.6	0.9 \times 0.3 \times 0.1	

Sumar de las filas

3º Multiplicamos los factores restantes y normalizamos

+ D-separa

D-separa si:

* Dada un valor $\{c\}$, este aparece en ~~entre~~ la red entre los valores o analizar como:
 $[x \rightarrow \dots \rightarrow c \leftarrow \dots \rightarrow y]$, $[x \leftarrow c \rightarrow \dots \rightarrow y]$ o $[x \leftarrow \dots \rightarrow c \rightarrow \dots \rightarrow y]$

* Dada un valor $\{c\}$, no aparece entre los valores; pero hay otro tal que:
 $[x \rightarrow \dots \rightarrow z \leftarrow \dots \rightarrow y]$